

Normas Matriciais

Existem muitas normas distintas que podem ser calculadas de uma matriz. Normas matriciais são de alguma forma similares a normas vetoriais em que cada norma fornece um número que caracteriza a matriz.

A norma é indicada usando duas linhas verticais, por exemplo, a norma da matriz A é indicada por $\|A\|$.

As normas matriciais podem ser amplamente divididas em duas famílias:

normas elementares (ou de entrada) e normas induzidas. As normas elementares não calculadas baseadas nos elementos individuais da matriz,

e portanto essas normas podem ser interpretadas para refletir as magnitudes dos elementos na matriz.

As normas induzidas pode ser interpretada da seguinte maneira: uma das funções de uma matriz é codificar a transformação de um vetor; a norma induzida de uma matriz é a medida de quanto essa transformação escalou (alongando ou contraindo) esse vetor.

Este capítulo irá abordar as normas elementares. A norma Euclidiana, também chamada de norma Frobenius, é uma extensão direta da norma vetorial. Ela é calculada como a raiz quadrada da soma de todos os elementos da matriz ao quadrado

$$\text{A norma Frobenius}$$

$$\|A\|_F = \sqrt{\sum_{i=1}^M \sum_{j=1}^N a_{ij}^2}$$

Os índices i e j correspondem as M linhas e N colunas. E a anotação subscrita F indica a norma Frobenius.

Essa norma também é chamada de norma ℓ_2 . Esse nome tem origem da fórmula geral para normas-p

$$\|A\|_p = \left(\sum_{i=1}^M \sum_{j=1}^N |a_{ij}|^p \right)^{1/p}$$

Perceba que você obtém a norma frobenius quando $p=2$

Uma das aplicações mais importantes das normas matriciais na análise estatística e Machine Learning é sua aplicação na regularização, cujo objetivo visa melhorar o ajuste do modelo e aumentar a generalização

Matrizes - 2

dos modelos aos dados novos. A ideia básica da regularização é adicionar uma norma matricial como uma função de custo a um algoritmo de minimização. Essa norma ajudará a evitar que os parâmetros do modelo se tornem muito grandes (a regularização também é conhecida por regressão Ridge) ou incentivar soluções esparsas (a regularização L1, também conhecida como regressão por lasso). As arquiteturas modernas de deep learning dependem das normas matriciais para alcançar desempenhos tão impressionantes na resolução de problemas de visão computacional.

Outra aplicação da norma de Frobenius é medir a "distância de Matriz". A distância matricial de uma matriz com ela mesma é 0, e a distância entre duas matrizes distintas aumenta a medida que os valores numéricos dessas matrizes se tornam mais diferentes.

Essa distância pode ser usada como um critério de otimização em machine

learning, por exemplo, para reduzir o tamanho de armazenamento de dados de uma imagem enquanto minimiza a distância de Frobenius entre as matrizes reduzida e a original.

Trago de Matriz e Norma de Frobenius

O trago de uma matriz é a soma de seus elementos diagonais, indicado por $\text{tr}(A)$, e só existe para matrizes quadradas. As duas matrizes a seguir têm o mesmo trago (14):

$$\begin{bmatrix} 4 & 5 & 6 \\ 0 & 1 & 4 \\ 9 & 9 & 9 \end{bmatrix}, \begin{bmatrix} 0 & 0 & 0 \\ 0 & 8 & 0 \\ 1 & 2 & 6 \end{bmatrix}$$

O trago tem algumas propriedades interessantes. Por exemplo, o trago de uma matriz é igual a soma de seus autovalores e portanto é uma medida de volume de seu autoespaço.

$$\|A\|_F = \sqrt{\sum_{i=1}^M \sum_{j=1}^N a_{ij}^2} = \sqrt{\text{tr}(A^T A)}$$

A norma de Frobenius pode ser calculada como a raiz quadrada do trago de uma matriz vezes sua transposta. Isso se deve ao caso

Matrizes - 2

que cada elemento diagonal da matriz $A^T A$ é definido pelo produto escalar de cada linha com ela mesma

Considerando alguns casos, o vetor $\begin{bmatrix} -2 & -6 \end{bmatrix}$ está no espaço colunar pois pode ser expressado com $\lambda = -2$. Porem $\begin{bmatrix} 1 & 4 \end{bmatrix}$ não é um vetor do espaço colunar da matriz porque não há escalar que possa multiplicar a matriz e produzir esse vetor.

Espaços Matriciais (colunas, linhas e nulos)

Espaços matriciais são conceitos simples e são essencialmente combinações lineares ponderadas de diferentes características de uma matriz.


Espaco Colunar

Primeiro nos conceitualizamos uma matriz como um conjunto de vetores coluna. Depois, consideramos um infinito de valores reais escalares em vez de trabalhar com um conjunto específico de escalares. Isso resultaria em infinitas formas de combinar um conjunto de vetores. Esse resultado infinito de conjunto de vetores é chamado de espaço colunar de uma matriz.

$$C\left(\begin{bmatrix} 1 \\ 3 \end{bmatrix}\right) = \lambda \begin{bmatrix} 1 \\ 3 \end{bmatrix}, \lambda \in \mathbb{R}$$

O $C(A)$ indica o espaço colunar da matriz A .

Para uma matriz com uma coluna, o espaço colunar é uma linha que atravessa a origem na direção do espaço vetorial e se alonga ao infinito em ambas as direções.



Considerando uma matriz com mais colunas:


$$C\left(\begin{bmatrix} 1 & 1 \\ 3 & 2 \end{bmatrix}\right) = \lambda_1 \begin{bmatrix} 1 \\ 3 \end{bmatrix} + \lambda_2 \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \lambda \in \mathbb{R}$$

Com duas colunas temos dois λ 's diferentes.


O conjunto de todos os vetores que podem ser alcançados por alguma combinação linear desses dois vetores de coluna são todos os vetores \mathbb{R}^2

Matrizes - 2

Por exemplo, o vetor $\begin{bmatrix} -4 & 3 \end{bmatrix}$ pode ser obtido escalonando as duas colunas por 11 e -15, respectivamente o espaço colunar dessa matriz está (esses escalares foram obtidos pelo método de projeção dos mínimos escalares)



Agora há 2 colunas em \mathbb{R}^3 . Elas são linearmente independentes. Então em 2D, mas é um plano 2D que está embutido em \mathbb{R}^3



Há muitos vetores no plano. Mas há muito mais vetores fora dele.

Outro exemplo é:

$$C \begin{pmatrix} 1 & 2 \\ 3 & 6 \end{pmatrix} = \lambda_1 \begin{pmatrix} 1 \\ 3 \end{pmatrix} + \lambda_2 \begin{pmatrix} 2 \\ 6 \end{pmatrix}, \lambda \in \mathbb{R}$$

Essas duas colunas são colineares por que uma já é a versão reduzida da outra. O que significa que o espaço colunar dessa matriz 2×2 é apenas uma linha - um subespaço 1D.

A dimensionalidade do espaço colunar é igual ao número de colunas apenas se as colunas forem um conjunto linear independente.

Um último exemplo:

$$C \begin{pmatrix} 3 & 0 \\ 5 & 2 \\ 1 & 2 \end{pmatrix} = \lambda_1 \begin{pmatrix} 3 \\ 5 \\ 1 \end{pmatrix} + \lambda_2 \begin{pmatrix} 0 \\ 2 \\ 2 \end{pmatrix}$$

Espaço Linear

O espaço linear de uma matriz tem o mesmo conceito do colunar, mas consideramos todas as possíveis combinações ponderadas das linhas ao invés das colunas.

$$R(A) = C(A^T)$$

O espaço linear é invariante as operações de redução de linha

Como $R(A) = C(A^T)$, esses dois espaços matriciais serão idênticos para matrizes simétricas.

Matrizes - 2

Espaços Nulos

O espaço colunar pode ser resumido como:

$$Ax = b$$

Enquanto o espaço nulo, em contraste:

$$Ay = 0$$

"Podemos achar um conjunto de pesos que não são todos 0 – e produzir o vetor zero?"

Qualquer vetor y que satisfaça esse equação está no espaço nulo de A , escrito por $N(A) = \{ \}$

Há uma estreita relação entre a dimensionalidade do espaço nulo e a independência linear das colunas em uma matriz.

O espaço nulo é vazio quando as colunas de matriz formam um conjunto linearmente independentes

$$A = np.array([[-1, -1], [2, 2]])$$

$$B = np.array([[-1, -1], [2, 3]])$$

```
print(scipy.linalg.null_space(A))
```

```
print(scipy.linalg.null_space(B))
```

Dada as infinitas vetores possíveis, o Python irá retornar um vetor unidimensional.

Os vetores unidimensionais são convenientes de trabalhar e têm ótimas propriedades como

a estabilidade numérica.

Rank (classificação)

Rank é um número associado a uma matriz. Ele está relacionado à dimensionalidade dos subespaços da matriz e tem importantes implicações para as operações de matrizes, incluindo a inversão de matrizes e a determinação do número de soluções para um sistema de equações.

Algumas propriedades do rank:

- É um número inteiro não-negativo.
- Toda matriz tem um único rank. (rank é a menor quantidade entre linhas ou colunas)
- É indicado por $r(A)$ ou $\text{rank}(A)$
- O rank máximo possível é a menor quantidade entre linhas e colunas.
- Uma matriz com o maior rank possível é chamada de "full-rank". Se $r < \min\{M, N\}$ então é chamada de "rank-reduzido".
- Multiplicações escalares não afetam o rank da matriz (com exceção do 0)

Há muitas interpretações e definições para o rank.

Matrizes - 2

- O maior numero de colunas (ou linhas) que formam um conjunto linearmente independente.
- A dimensionalidade do espaço colunar (que é a mesma dimensionalidade do espaço triangular tem sua classificação completa apenas se houver valores diferentes de zero em todos os elementos da diagonal. Se houver pelo menos um zero na diagonal a matriz será de rank reduzido. (O rank exato irá depender dos valores numéricos da matriz).
- O numero de dimensões que contém informações na matriz.
- A quantidade de valores singulares diferentes de zero na matriz.

Ranks de Matrizes especiais

- Vetores: Todos os vetores tem rank 1. Isso porque vetores só possuem uma coluna (ou linha) de informação. A unico elemento da matriz foram extraídos e excessão é o vetor zero.
 - Matriz zero: uma matriz zero de qualquer tamanho (incluindo o vetor zero) tem o rank 0.
 - Matrizes Identidade: O rank da matriz identidade é igual ao numero de linhas/coluna. Ou seja, $r(I_N) = N$.
 - Matrizes Diagonais: O rank de uma matriz diagonal é igual a quantidade de elementos diferentes de zero na diagonal. Isso porque cada linha contém no maximo um elemento diferente de zero,
- e é impossível criar um numero diferente de zero por meio de combinações ponderadas de zero.
- Matrizes Triangulares: Uma matriz

de uma matriz aleatoria é impossível de ser determinada a priori, porque ela depende da distribuição de numeros de qual os elementos da matriz foram extraídos e da probabilidade de extrair cada numero. Matrizes criadas com `np.random.rand()` terão o maximo de classificação possível.

Rank de Matrizes adicionadas e multiplicadas

A classificação de duas matrizes individuais fornecem limites para a maxima classificação possível:

$$\text{rank}(A+B) \leq \text{rank}(A) + \text{rank}(B)$$

$$\text{rank}(AB) \leq \min\{\text{rank}(A), \text{rank}(B)\}$$

Matrizes - 2

Memorize:

- Você não consegue saber a classificação exata de uma matriz somada ou multiplicada se baseando apenas na classificação das matrizes individuais.

As matrizes individuais fornecem limites superiores a classificação das matrizes somadas ou multiplicadas.

• A classificação de uma matriz somada um vetor está no espaço colunar pode ser maior que a classificação das matrizes individuais

• A classificação de uma matriz multiplicada não pode ser maior do que a maior classificação das matrizes de multiplicação.

uma matriz.

Aumentar uma matriz significa adicionar colunas extras ao lado direito da matriz

$$\begin{bmatrix} 4 & 5 & 6 \\ 0 & 1 & 2 \\ 9 & 9 & 4 \end{bmatrix} \cup \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} = \begin{bmatrix} 4 & 5 & 6 & 1 \\ 0 & 1 & 2 & 2 \\ 9 & 9 & 4 & 3 \end{bmatrix}$$

O algoritmo para determinar se

1. Aumente a matriz com o vetor.

Vamos chamar a matriz original de A e a matriz aumentada de \tilde{A} .

2. Calcule o rank das duas matrizes

3. Compare os dois ranks.

a. $\text{rank}(A) = \text{rank}(\tilde{A}) \rightarrow$ vetor v está no espaço colunar da matriz A .

b. $\text{rank}(A) < \text{rank}(\tilde{A}) \rightarrow$ vetor v não está no espaço colunar da matriz A .

Independencia linear de um conjunto vetores

O algoritmo é direto: coloque os vetores em uma matriz, calcule o rank da matriz e então compare o rank ao rank máximo possível da matriz.

Aplicações de Rank

No espaço colunar?

Antes de explicar o algoritmo para determinar se $v \in C(A)$, é necessário explicar o procedimento chamado aumento de

Matrizes - 2

• $r = M$: O conjunto vetor é linearmente independente

• $r < M$: O conjunto vetor é linearmente dependente

fão matriz-vetor. Uma determinante negativa significa que um eixo é rotacionado durante a transformação.

Calcular o Determinante

$$\det \begin{pmatrix} a & b \\ c & d \end{pmatrix} = \begin{pmatrix} a & b \\ c & d \end{pmatrix} = ad - bc$$

A determinante não é limitada a valores inteiros ou positivos.

Calcular a determinante é simplesmente o produto da diagonal menos o produto da diagonal inversa.

$$\begin{vmatrix} a & b & c & d \\ e & f & g & h \\ i & j & k & l \\ m & n & o & p \end{vmatrix} = afkp - aflo - agjp + agln + ahjo - ahkn - bekp + belo + bgip - bglm - bhio + bhkm + cejp - celn - cfip + cflm + chin - chjm - dejo + dekn + dfio - dfkm - dgin + dgjm$$

As duas propriedades mais importantes dos determinantes são:

1. Só é válida para matrizes quadradas np.linalg.det() # ou
2. É zero para matrizes de rank reduzido scipy.linalg.det()

No python:

A determinante é anotada como $\det(A)$ ou $|A|$. A letra Grega maiúscula delta Δ é usada quando você não precisa fazer referência a uma matriz específica

Determinantes com Dependências

Lineares

Como foi dito anteriormente, a determinante para qualquer matriz reduzida é zero.

$$\begin{vmatrix} a & \lambda a \\ c & \lambda c \end{vmatrix} = ac\lambda - a\lambda c = 0$$

Esse conceito generaliza para matrizes

A determinante tem uma interpretação geométrica, que é relacionada a quanto a matriz alonga vetores durante a multiplicação

Matrizes - 2

maiores.

A característica polinomial

A combinação de matriz deslocada com a determinante é chamada de característica polinomial de matriz

$$\det(A - \lambda I) = \Delta$$

$$\begin{vmatrix} a-\lambda & b \\ c & d-\lambda \end{vmatrix} = 0 \Rightarrow \lambda^2 - (a+d)\lambda + (ad - bc) = 0$$

$$\begin{vmatrix} a-\lambda & b & c \\ d & e-\lambda & f \\ g & h & i-\lambda \end{vmatrix} = 0 \Rightarrow \begin{aligned} & -\lambda^3 + (a+e+i)\lambda^2 \\ & +(-ae+bd-ai+cg-ei+fh)\lambda \\ & +aei-afh-bdi+bfg+cdh-ceg = 0 \end{aligned}$$

$$\det\left(\begin{bmatrix} 1 & 3 \\ 3 & 1 \end{bmatrix} - \lambda I\right) = 0$$

$$\begin{vmatrix} 1-\lambda & 3 \\ 3 & 1-\lambda \end{vmatrix} = 0 \Rightarrow (1-\lambda)^2 - 9 = 0 \Rightarrow 1-\lambda = \pm 3 \Rightarrow$$

$$\Rightarrow \lambda_1 = -2, \lambda_2 = 4$$

$$\begin{aligned} \lambda = -2 & \rightarrow \begin{bmatrix} 3 & 3 \\ 3 & 3 \\ -3 & 3 \end{bmatrix} \\ \lambda = 4 & \rightarrow \begin{bmatrix} 3 & -3 \\ 3 & -3 \end{bmatrix} \end{aligned}$$

As duas matrizes tem rank 1. Além disso, ambas possuem espaços nulos não triviais, o que significa que você pode encontrar alguns vetores γ diferentes de zero que satisfaçam $(A - \lambda I)\gamma = 0$.

Resumo

- Há muitos tipos de normas matriciais, que podem ser amplamente classificadas em elementares e induzidas. O primeiro reflete a magnitude dos elementos na matriz enquanto o último reflete o efeito geométrico-transformativo da matriz no vetor.

- A norma elementar mais comumente usada é a norma de Frobenius (conhecida por norma Euclidiana ou norma $\| \cdot \|_2$) e é calculada como a raiz quadrada da soma dos elementos ao quadrado.

- O traço da matriz é a soma dos elementos diagonais

- Há quatro espaços matriciais (colunar, linear, nulo e nulo-esquerdo), e eles são definidos como o conjunto de combinações lineares ponderadas de diferentes características da matriz.

- O espaço coluna da matriz compreende toda a combinação linear ponderada das colunas na matriz e é escrito como $C(A)$.

- O espaço linha da matriz compreende toda a combinação linear ponderada das linhas na matriz e é escrito como $R(A)$ ou $C(\bar{A})$

Matrizes - 2

• O espaço nulo da matriz é o conjunto de vetores que combinam linearmente as colunas para produzir o vetor zero, em outras palavras, qualquer vetor y que resolva a equação $Ay=0$. A solução trivial $y=0$ é excluída. O espaço nulo é importante para encontrar os auto vetores, entre outras aplicações.

• Rank é um inteiro não negativo associado a uma matriz. O rank reflete a maior quantidade de colunas (ou linhas) que formam um conjunto linearmente independente. Matrizes com um rank menor que o máximo possível são chamadas de rank reduzidas ou singulares.

• Deslocar uma matriz quadrada adicionando uma constante à diagonal assegura o rank completo

• Uma das muitas aplicações do rank é determinar se um vetor está no espaço coluna de matriz.

• A determinante é um número associado a matriz quadrada. Ela é 0 para todas as matrizes de rank reduzido e diferente de zero para as de rank completo

• A característica polinomial transforma uma matriz quadrada, deslocada por λ , em uma equação igual a determinante